

VideoOps-RL：多模态多智能体 Agentic RL 全链路笔记

Algorithm v2：训练前离线闭环

1 问题与项目边界

输入长视频和一句自然语言查询，系统输出相关高光时间段、证据和完整工具轨迹。普通 VLM 往往直接生成答案；VideoOps-RL 把过程建模为带工具预算的序列决策：检索候选、核验证据、扩展时间上下文、审计，再决定继续或提交。

状态由 query、候选信念、已核验节点、剩余预算和审计状态组成；动作是工具调用；观测是字幕、图像、特征和时间信息；ground truth 只由环境计算奖励，绝不进入公开 prompt。RL 学的是如何取证和停止，不是从零学习视觉知识。

项目与长视频切分、Keyframe/Chunk、结构化剧情理解和内容运营方向对齐，但使用公开数据独立实现，不声称使用企业内部数据、服务或代码。目标是可运行、可消融、面试可解释的工程 POC，不是论文 SOTA。

2 双数据栈

2.1 QVHighlights：规模与人工标签

接入 QVHighlights 官方人工查询、时间窗口和公开 2 秒 OpenAI CLIP 特征。train/val/test 分别有 7,218/1,550/1,542 个任务，共 10,310 个任务、10,148 个视频；三个 split 的视频交集为 0。原始视频不重新分发，项目只保存运行所需的公开特征、标注、许可证和来源清单。

split	任务	视频	标注窗口
train	7,218	7,100	12,803
val	1,550	1,519	2,803
test	1,542	1,529	2,761

2.2 开放电影：原始多模态链路

三部 Blender CC BY 影片提供 306 个真实关键帧、178 条字幕和 66 个业务式任务。Tears of Steel、Sintel、Big Buck Bunny 按整部视频划分，避免相同角色、画风和字幕泄漏。该数据验证 BM25 字幕检索、CLIP 关键帧检索和图像注入 VLM 的真实工具链。

两套数据互补：QVHighlights 负责规模、人工标签和手工视觉标签的留出评测；开放电影负责字幕、原始图片和业务流程。GRPO 以 80%/20% 混合采样二者。

3 核心算法

3.1 多模态时序证据图

每个镜头或 2 秒 clip 是一个节点，保存文本分数 s_i^t 、视觉分数 s_i^v 、上下文分数 s_i^c 和核验状态。字幕由 BM25 检索，视觉由 OpenAI CLIP ViT-B/32 检索。候选信念使用 Noisy-OR：

$$b_i = 1 - \prod_{m \in \{t, v, c\}} (1 - w_m s_i^m). \quad (1)$$

单个模态的低分不会抹掉另一模态的强证据；多模态共同支持时，信念继续上升。上下文扩展时，中心证据按

$$s_j^c = \max(s_j^c, b_i e^{-0.7|i-j|}) \quad (2)$$

传播到相邻节点。

3.2 变量长度时间段解码

最高相似度的 2 秒 clip 无法覆盖长事件，固定窗口又不适合不同时长。v2 解码器依次执行：五点移动平均；取 72% 分位数与 $0.52 \max(s)$ 的较大值作为动态阈值；提取连续区域；左右各补两个 clip；按 $0.55 \text{ mean} + 0.45 \text{ max}$ 排序得到变量长度 proposal。

Agent 先核验 proposal 的 anchor，再调用半径为 0 的上下文扩展接收整个自适应区间。该过程不读取目标标签。

3.3 权限分离的多 Agent

QueryRouter 只看 query 和视频是否有对白；TimelineScout 只允许字幕检索与上下文扩展；VisionAnalyst 只允许视觉检索与候选核验；EvidenceAuditor 只做证据审计；Coordinator 读取共享证据图并决定提交。

环境有硬约束：未检索候选不能核验，未核验 anchor 不能扩展，未接地片段不能提交。多 Agent 的实质是状态共享下的职责与权限隔离，而不是多个模型自由聊天。

4 Reward 与 Agentic RL

过程奖励用于解决长链路信用分配，包括：正确候选 reciprocal-rank 提升、正确/错误核验、上下文 recall 增益、正确/误报审计、非法动作和非法提交。

终局奖励为

$$\begin{aligned} R = & 2.00tIoU + 0.35F_1^{shot} + 0.30S_{audit} \\ & + 0.20C_{modality} + R_{process} - 0.025N_{tool} \\ & - 0.06N_{repeat} - 0.20N_{invalid}. \end{aligned} \quad (3)$$

QVHighlights 另加最高 0.10 的人工 saliency 奖励。审计分数只由语义信念、模态覆盖和时间连续性计算；标签命中只作为隐藏 reward，不作为模型观察。

只奖励 tIoU 会鼓励猜时间；只奖励审计会鼓励机械调用；只有同时加入过程信号、证据质量和成本，策略才有动力学习“搜什么、看什么、扩多远、何时停”。

5 训练数据与 24 卡执行

规则专家运行全部任务，但只有成功且审计通过的轨迹进入 SFT。当前 SFT train/val/test 分别为 3,575/776/782 条。GRPO train 有 9,018 条无标签泄漏采样记录，其中 QVHighlights 7,218 条、开放电影重复为 1,800 条，实现约 80%/20% 的特征与原始图像环境混合，并保留成功与失败任务供策略探索。

SFT 先学习合法 JSON、工具参数、证据引用和停止格式；GRPO 每个 prompt 采样 4 条 rollout。外部 dataset 向同组环境传递相同 task ID，避免独立随机抽题造成任务难度噪声，再通过组内相对 reward 优化模态选择、候选核验、时间扩展、审计和停止。直接跳过 SFT 时，大量输出无法形成合法工具调用，组内 reward 接近同一个失败值。

服务器执行顺序：24 卡 ZeRO-2 LoRA SFT；在 GPU 0 合并 LoRA；GPU 20-23 启动 TP=4 vLLM；GPU 0-19 做 GRPO；最后把 val/test 各拆成 12 个 shard 并行评测。脚本自动检测 8/24 卡模式，并包含 vLLM health check、失败退出、进程清理和评测合并。

6 训练前消融结果

QVHighlights 完整 val/test 共 3,092 个任务均已评测，无缺失特征。结果使用项目实现的单预测 R@1-style temporal IoU，不能写成官方 mAP。

方法	V-IoU	V-R@.5	T-IoU	T-R@.5
峰值 2 s	.054	.000	.052	.000
固定 10 s	.235	.108	.227	.100
自适应 proposal	.482	.499	.487	.501

这说明当前最明确的算法增益来自动态边界解码，而不是角色包装。40 个本地测试已通过，覆盖融合信念、硬约束、标签隔离、同组状态固定、时序 proposal、审计和多片段提交。

7 诚实边界与服务器验收

已完成：公开数据与特征、查询向量、原始多模态证据、环境、工具、时序图、过程/终局 reward、成功 SFT 轨迹、GRPO prompt、消融、测试、模型权重和离线打包。

未完成：H200 上的 SFT/GRPO、训练后工具合法率、组内 reward 方差、吞吐/显存和 checkpoint 指标。因此当前只能写“实现全链路并完成训练前消融”，训练跑完后才能写“完成 SFT+GRPO 并提升指标”。

Smoke go 条件：24 卡和全部离线资产通过预检；SFT loss 正常下降；工具 JSON 可解析；四条 rollout 的 reward 有方差；关键帧真正进入 VLM；vLLM 服务健康；显存不超过容量 90%。任一项失败就停止 200-step 正式 POC。

8 面试两分钟讲法

我把长视频查询定位建模成受工具预算约束的 Agentic RL。底层用 BM25 和 CLIP 构建候选，再用 Noisy-OR 时序证据图融合模态并传播上下文。为解决单 clip 峰值无法覆盖长事件，我实现了平滑、动态阈值、连通区域和 proposal ranking 的变量长度解码器，在 QVHighlights 完整 val/test 上把固定 10 秒窗口约 10% 的 R@1@0.5 提升到约 50%。上层把检索、视觉核验、审计和协调拆成权限隔离的 Agent，并用硬接地约束防止伪造证据。训练采用成功轨迹 LoRA SFT，24 卡模式下做 20+4 卡 GRPO/vLLM，并用 24 卡并行评测；训练后增益等 H200 日志产生后再报告。

8.1 关键追问

为什么需要 RL？因为模态选择、搜索、核验、扩展、审计和停止构成有成本的序列决策，单条监督轨迹不能直接优化效果与成本的全局折中。

多 Agent 有什么算法意义？它约束动作空间与证据权限，并通过共享证据图协作；不是为了增加角色数量。

数据真实吗？QVHighlights 是公开人工查询/时间标注，开放电影是真实公开媒体；不冒充生产数据。公开电影少量媒体标签只作辅助，零手工标签结论以 QVHighlights 为准。

最大的风险？GRPO 训练效果尚未产生；SFT teacher 只有约一半任务成功，因此只保留成功轨迹，失败 prompt 留给 RL 探索。